Workshop Intensivo de Aplicações Modernas de Ciência de Dados com Machine Learning


Turma 2

Terceiro dia


Paulo Cysne Rios Jr.

Overfitting e Underfitting

Fitting uma linha




Overfitting em Regressão




Overfitting em Regressão

Linha vermelha = função real dos dados Linha azul = Modelo



Overfitting em Classificação



Solução curvilínea

Overfitting

Solução Linear

Fontes de Erros na Nossa Modelagem

- Fontes de erros nas nossas modelagens são devidos a:
- Bias (viés)
- Variance (variância)
- Erros irredutíveis (da coleta de dados)

Bias (Viés)

- Nossa tendência e necessidade em simplificar nossos modelos para fazê-los mais compreensíveis.
- Esta parte do erro de generalização deve-se a suposições erradas, como assumir que os dados são lineares quando é realmente quadrático.
- Um modelo de alto viés é mais provável de prejudicar os dados de treinamento.

Variance

- Variance (Variância): a flexibilidade do nosso modelo de mudar com novos dados.
- Esta parte é devido à sensibilidade excessiva do modelo a pequenas variações nos dados de treinamento.
- Um modelo com muitos graus de liberdade (como um modelo polinômico de alto grau) provavelmente terá alta variação e, portanto, superará os dados de treinamento.

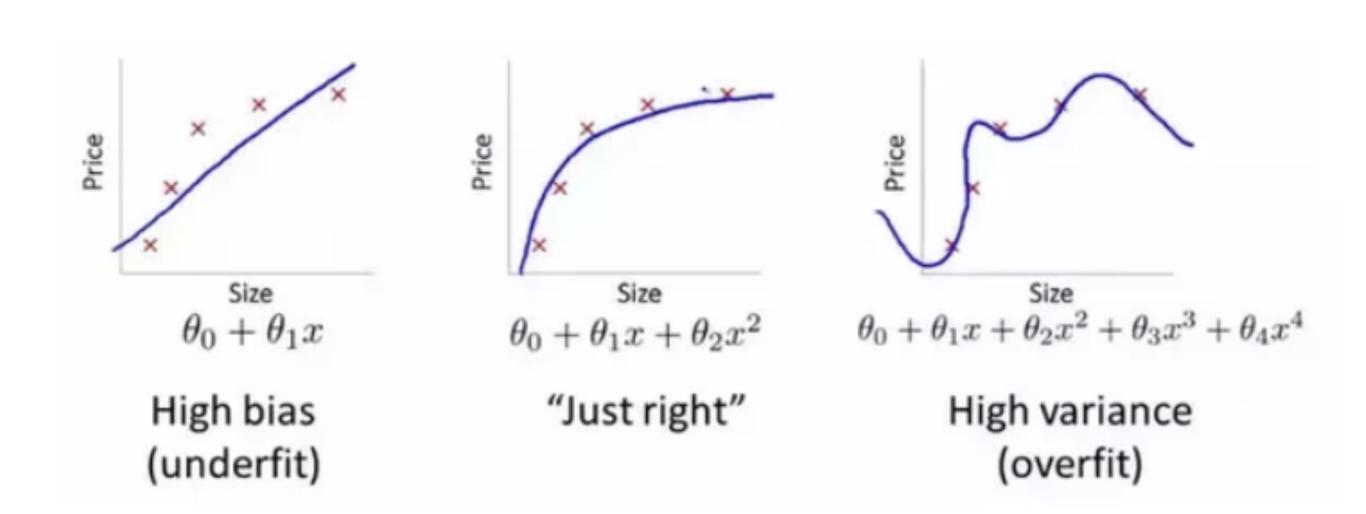
Erros irredutíveis

- Esta parte é devido ao noise (barulho) dos dados em si.
- A única maneira de reduzir esta parte do erro é limpar os dados.
- Por exemplo, corrigir as fontes de dados, como sensores quebrados, ou detectar e remover outliers.

Bias Variance Tradeoff

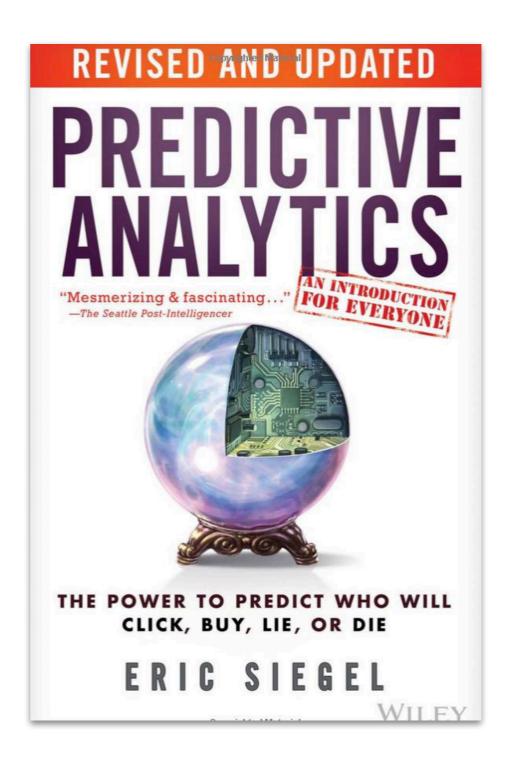
- Se aumenta um, o outro diminui!
- Aumentar a complexidade de um modelo geralmente aumentará sua variação e reduzirá seu viés.
- Por outro lado, reduzir a complexidade de um modelo aumenta seu viés e reduz sua variação.
- É por isso que se chama tradeoff / troca.

Bias Variance Tradeoff



Ciência de Dados e Analítica Preditiva

- Qual a diferença entre
 Ciência de Dados e
 Analítica Preditiva?
- Resposta na próxima aula!
 Tente descobrir....



Aplicações

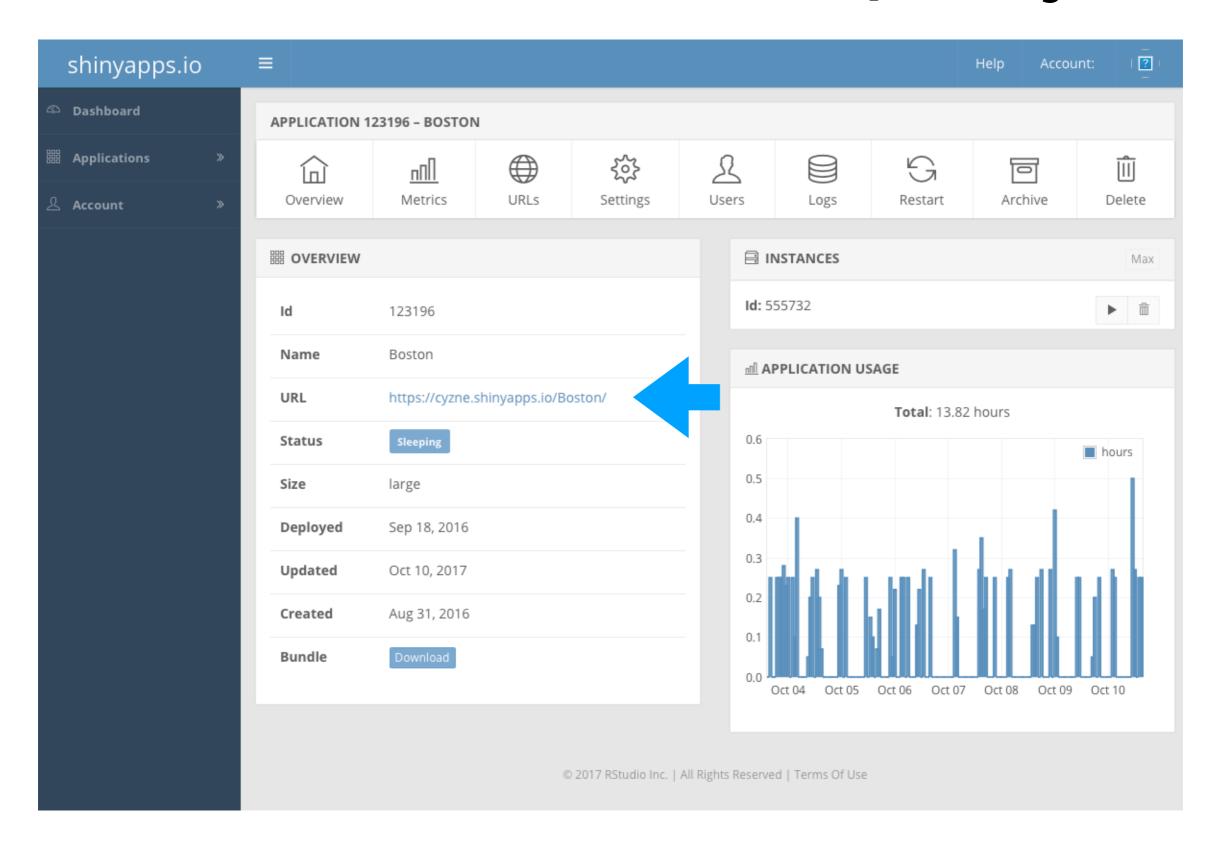
- Cite 5 aplicações de Ciência de Dados na sua empresa
- Cite 5 aplicações em geral de Ciência de Dados
- Escreva num papel que coletaremos antes do final da aula de hoje
- para que possamos mostrar exemplos relacionados às aplicações que mais lhe interessam!

Prática

Exemplo: 2 Aplicativos Meus de Predição

- Um deles que fiz com predição de valores de imóveis usando um conjunto de dados real. Outro de doenças coronárias.
- Foram feitos em **R** (no excelente ambiente **RStudio**) e disponibilizado na web usando a ferramenta **Shiny** (do R).
- A rápida reação do programa ao input do usuário mostra como se pode disponibilizar um modelo analítico para uso pela Internet.
- Faremos ao longo do workshop uma modelagem semelhante com **Python** e em especial também com **Deep Learning**.

Servidor das Minhas aplicações



Minhas 2 aplicações

• Predição de preços de imóveis

https://cyzne.shinyapps.io/Boston/

Predição de doença coronária

https://cyzne.shinyapps.io/Coronary/

Minha Aplicação de Predição de Preços de Imóveis

Usando um conjuntos de dados reais disponíveis na Internet

DataCyz - Predicting Prices and Their Most Important Features

By Paulo C. Rios, Jr., September, 2016

Use the menus to do the following:

About

Understanding this application and the data

Introduction - A description of this webbased analytical application

Conclusions - Our findings and conclusions

Features - Description of each feature of the data set

Dataset - The data with all features in a searchable and sortable form

Data Visualization

Exploring and visualizing the data

Frequency - Chart with the frequency of each selected feature

Relationships - Plot of each feature against price to investigate their relationship

Analytics

What we have learned from the data

Importance - Which features have most impact on the house price

Accuracy - A chart and a table of all actual vs. predicted house prices values, including the mean error

Predictions - With the given feature values, we predict the target value, that is, the house price, with high accuracy

Search

Finding suitable prices

Using our analytical model, it is possible to look for houses using the 2 most important features (the ones we discovered in the Importance tab)

About ▼ Data Visualization ▼ Analytics ▼ Search

House Price Analytics



Summary

This web application shows how advanced data analytics are not only powerful, but can also be easily made available and used over the Internet. This site is fully dynamic. All the analytics and charts are generated on the fly, using the source data described below.

The data

The Boston data set contains information collected by the U.S Census Service concerning housing in the area of Boston, Mass. It has 506 entries (that is, houses) and 14 features for each entry. Our main interest is our target feature, the median house value, as we describe below.

Objectives

In this web application we have three main goals:

- 1. To identify which of the features most affect the house value,
- To predict the house value using the given other features in the data set,
- To allow the discovery of the best opportunities in this house market

As we show in the other tabs, these goals have been fully met. In the summary tab, we also describe what we have achieved. Check the different tabs to access different resuls and capabilities of this advanced data analytics. A description of each tab is conveniently located in the panel on the left.

About ▼ Data Visualization ▼ Analytics ▼ Search

Choose one of two statistical measures below to identify **the most important features** to determine the house price. They are listed below in both chart and table format.

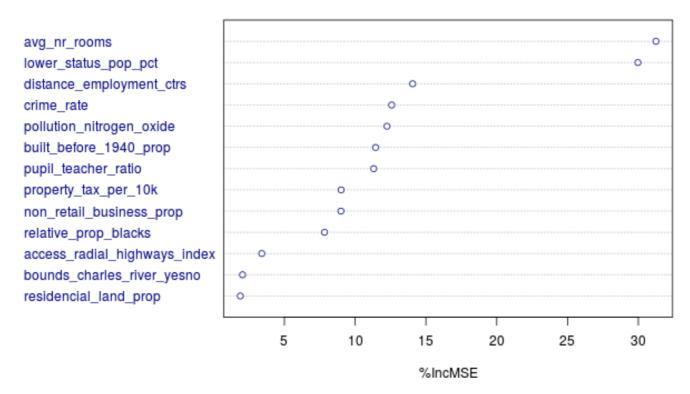
Mean decrease in accuracy ▼

Os atributos mais importantes são revelados

Importance Chart

Those features listed first and with a high statistical measure value are most valuable:

Most Important Features for Price - By Accuracy



Importance Table

They are also listed below in a table format. The higher their statistical measure, the more importance they have:

X.IncMSE	house.variable	
31.25	avg_nr_rooms	
29.97	lower_status_pop_pct	
14.06	distance_employment_ctrs	

2 atributos são muito mais importantes que os outros

About ▼ Data Visualization ▼ Analytics ▼ Search

Using the original Boston data set, the house values were predicted using our analytical model.

The error is measured by the mean difference between the actual and the predicted values.

Mean prediction error = 3.4

Chart with the predictions

O gráfico é quase uma linha, quer dizer está muito bom!


This plot compares the actual and predicted house values.

The ideal case is when this plot results in a straight line, but note that it is very close to one. However, it can also be seen that for high house values our errors are higher.

Actual vs. Predicted House Values







Minha Aplicação de Previsão de Doenças Coronárias

DataCyz - Coronary Disease Prediction

by Paulo C. Rios Jr., December 2015, updated September 2016

Using the input entered below, this application calculates a risk level in % for the onset of coronary diseases. It also compares the risk to an ideal healthy level.

Health indicators

Please enter your health data as requested below and press submit to see your results

Bad/LDL Cholesterol Level

Glicose Level

< 100</p>

90

>= 100 and < 200

>= 200

Physical Activity

< 3 hours per week</p>

>= 3 hours per week but not intense

Very intense

High Blood Pressure?

Yes

Submit

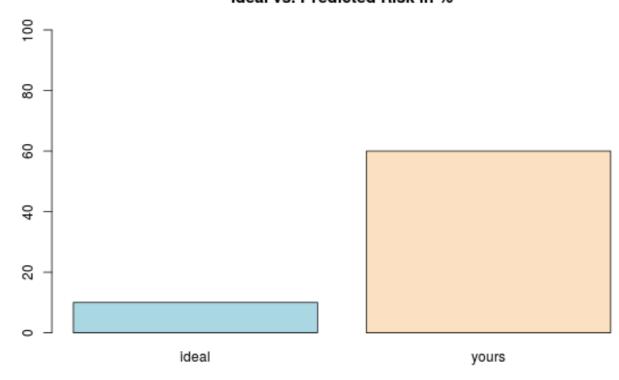
Results

Your chances of having any kind of coronary diseases are measured in a scale from 0 % (very low) to 100 % (very high).

According to your inputs, your risk level is:

60 %

Ideal vs. Predicted Risk in %



Laboratório

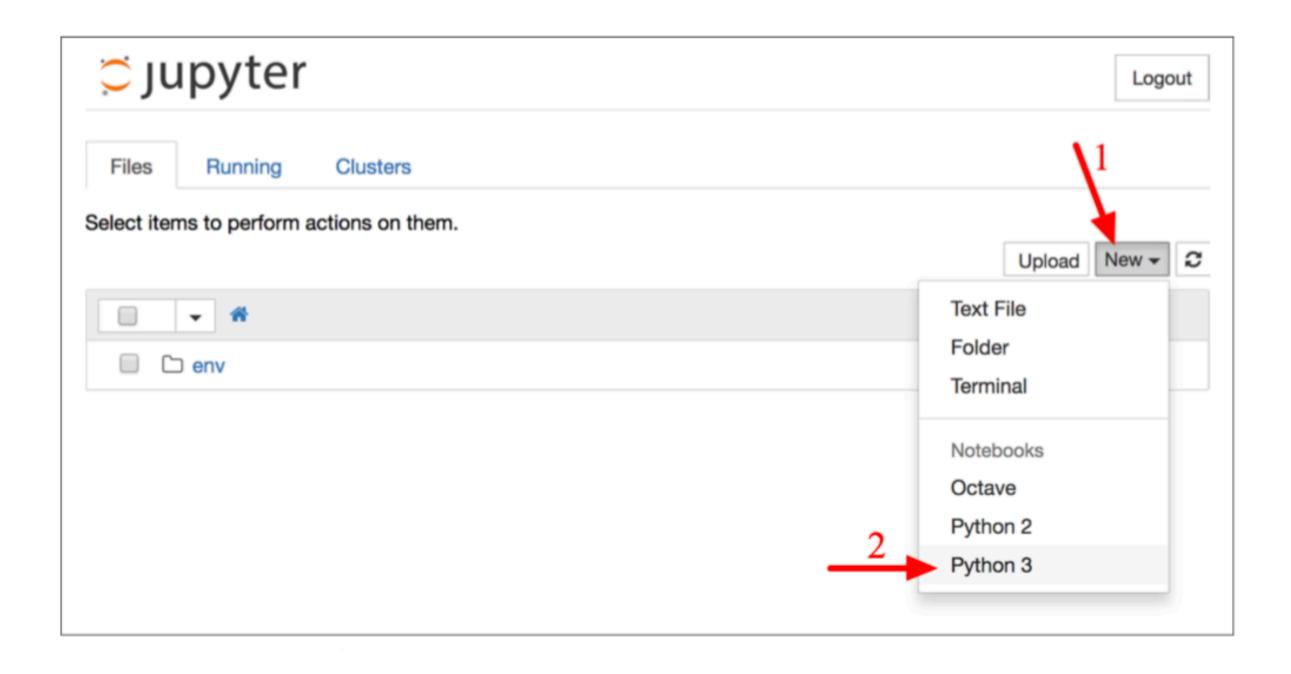
- Cheque se Anaconda está instalado
- Comece um Jupyter Notebook
- Tentaremos fazer algo com Python neste Jupyter Notebook
- Sabe como instalar alguma package que falta?

Anaconda Comandos mais utéis

- Para instalar uma nova package:
 Conda install nome-da-package
- Para atualizar uma nova package:
 Conda update nome-da-package
- Para obter a lista das packages instaladas:
 Conda list
- Para obter informações sobre a instalação:
 Conda info

```
ZireImac:~ Zireimac$ conda info
Current conda install:
              platform: osx-64
         conda version: 4.3.24
      conda is private : False
     conda-env version: 4.3.24
   conda-build version: not installed
        python version: 3.6.1.final.0
      requests version: 2.14.2
      root environment : /Users/Zireimac/anaconda (writable)
   default environment : /Users/Zireimac/anaconda
      envs directories : /Users/Zireimac/anaconda/envs
                         /Users/Zireimac/.conda/envs
         package cache : /Users/Zireim ZireImac:~ Zireimac$ conda list
                         /Users/Zireim # packages in environment at /Users/Zireimac/anaconda:
          channel URLs : https://conda#
                         https://conda_license
                                                                 1.1
                                                                                          py36_1
                         https://repo.alabaster
                                                                 0.7.10
                                                                                          py36_0
                         https://repo.anaconda
                                                                                          py36_0
                                                                 custom
                                       anaconda-client
                                                                 1.6.3
                                                                                          py36_0
                                       anaconda-navigator
                                                                 1.6.2
                                                                                          py36_0
                                                                 0.6.0
                                       anaconda-project
                                                                                          py36_0
                                                                 0.1.0
                                                                                          py36_0
                                       appnope
                                                                 1.0.1
                                       appscript
                                                                                          py36_0
                                                                 0.6.0
                                                                                                    conda-forge
                                                                                     np112py36_1
                                       arrow-cpp
                                       asn1crypto
                                                                 0.22.0
                                                                                          py36_0
                                       astroid
                                                                 1.4.9
                                                                                          py36_0
                                                                 1.3.2
                                                                                     np112py36_0
                                       astropy
                                       babel
                                                                                          py36_0
                                                                 2.4.0
                                       backports
                                                                 1.0
                                                                                          py36_0
                                       backports.weakref
                                                                 1.0rc1
                                                                                                    conda-forge
                                                                                          py36_0
                                                                 1.1.0
                                                                                                    conda-forge
                                       basemap
                                                                                          py36_2
                                       basemap-data-hires
                                                                 1.1.0
                                                                                                    conda-forge
```

Criando um novo notebook



No Jupyter Notebook

```
import sys
print(sys.version)
```

```
>>> import platform
>>> platform.python_version()
'2.6.2'
```

No Terminal (Mac) ou na Command Shell (Windows)

```
python --version
```

Exemplo em Python

- Vamos fazer um "code along".
- Vamos digitar juntos o código de Python a seguir num Jupyter Notebook.
- Ele representa um regressão linear feita em Python com a package SciKit-Learn (a package mais usada em Machine Learning). Os conjuntos de dados estão no repositório do workshop.
- Não se preocupe em entender tudo agora! Veremos tudo isso em detalhe mais à frente.